

Paso 1. Guía caso-taller: ¿A quién deja entrar el algoritmo?



Descomposición en valores singulares (SVD), *eigenfaces* y una recomendación de acción

El caso

Una empresa que administra edificios corporativos evalúa reemplazar las tarjetas de acceso por **reconocimiento facial en los torniquetes de entrada**. El hardware previsto es de bajo costo: cámaras sencillas y dispositivos con poca memoria y sin GPU, por lo que no es viable almacenar imágenes completas ni ejecutar modelos pesados. El equipo de producto propone una tecnología clásica y liviana: representar cada rostro mediante unas pocas coordenadas sobre una base de ***eigenfaces*** construida mediante la **descomposición en valores singulares (SVD)**.

La idea de este sistema es la siguiente: en vez de guardar la foto completa de cada empleado, el sistema aprende un pequeño conjunto de “rostros base” y describe cada cara con unas pocas coordenadas sobre ellos. Ese conjunto se aprende y se guarda una sola vez, compartido por todos. Para incorporar una persona al sistema solo es necesario agregar unas pocas dimensiones (K), no su imagen entera: ese es el **costo marginal** de cada empleado, y por eso elegir K es la decisión clave del piloto.

Antes de invertir en el piloto, el cliente necesita evidencia. Como la empresa todavía no tiene fotos de los empleados de sus edificios, el prototipo se construirá sobre una base pública de referencia: **Labeled Faces in the Wild (LFW)**, un estándar académico con miles de rostros etiquetados recopilados de la prensa.

El cliente los contrató para elaborar una recomendación clara de decisión mediante una presentación en video. Desde el primer minuto, la presentación debe ser clara respondiendo la pregunta del cliente:

¿Debe la empresa lanzar el piloto de reconocimiento facial basado en *eigenfaces*? Y si es así, ¿con cuántas dimensiones por rostro (K) y bajo qué salvaguardas?

Concretamente, la presentación debe tener:

1. **Una recomendación clara:** implementar o no hacerlo sobre los resultados del piloto.

2. **La evidencia que la sostiene**, capaz de responder las preguntas del cliente: ¿cuánto menos hay que guardar por rostro frente a la imagen completa? ¿Un *accuracy* de 90% es tan bueno como suena? ¿Qué es peor: rechazar a un empleado o dejar entrar a un extraño? ¿Funciona igual de bien para todos los géneros, razas o etnias?

Los datos

Los datos provienen de **Labeled Faces in the Wild (LFW)**, una base publicada por la Universidad de Massachusetts Amherst para la evaluación académica de sistemas de reconocimiento facial (Huang et al., 2007). Contiene más de 13.000 imágenes de rostros recopiladas de la web, cada una etiquetada con el nombre de la persona. El método de *eigenfaces* que aplicarán fue propuesto por Sirovich y Kirby (1987) y llevado al reconocimiento facial por Turk y Pentland (1991): una forma rudimentaria pero muy instructiva de resolver el problema.

Para que los resultados sean comparables entre grupos, trabajen con estos parámetros fijos:

- Carguen la base con `fetch_lfw_people(min_faces_per_person=25, data_home='data')`: solo individuos con al menos 25 fotos.
- Partición entrenamiento/prueba **80/20** con `random_state=10101`.
- Clasificador logístico con `LogisticRegression(solver='sag', random_state=10101, max_iter=1000)`.

Importante (desbalance de clases): las imágenes están muy desigualmente repartidas entre personas: unas pocas figuras públicas concentran gran parte de las fotos y, aun así, la persona más fotografiada es una fracción minoritaria del total. Cualquier métrica de desempeño que le presenten al cliente debe leerse a la luz de este desbalance. Ignorar este detalle puede hacer que un sistema poco confiable parezca excelente.

Nota de contexto: LFW se compiló hacia 2007 con fotos de prensa de personajes públicos, y su composición demográfica no representa a la población de empleados de un edificio corporativo. Parte de su trabajo como asesores es decidir qué limitaciones implica esto y advertírselas al cliente.

Los productos de la entrega

El único entregable es un **video de 10 a 15 minutos** (100% de la calificación), evaluado por sus pares con la rúbrica correspondiente, disponible en la plataforma.

Es una presentación ejecutiva dirigida al cliente, no un recorrido por el análisis: su propósito es comunicar la decisión (la recomendación y la evidencia que la sustenta), no explicar el código.

En esta actividad no se solicita que entregue un cuaderno o scripts que respalden su análisis, pero se espera que toda cifra o gráfica del video provenga de un análisis que el grupo pueda sustentar. Si el profesor complementario identifica inconsistencias, conflictos de interés, falta de justificación o cualquier otra circunstancia, podrá solicitarle los códigos que respalden su análisis. Es buena práctica, entonces, tenerlos debidamente documentados.

Este caso-taller busca evaluar su capacidad para integrar una representación no supervisada, aprendida mediante SVD, con las herramientas de modelación supervisada vistas previamente en la maestría.

Guía recomendada de análisis

La siguiente guía propone una ruta para desarrollar el análisis. No constituye una receta única: cada equipo podrá tomar decisiones metodológicas diferentes, siempre que sean técnicamente correctas, estén claramente documentadas y sean coherentes con la pregunta planteada en el taller.

Paso 1: Exploración de los datos

Carguen los datos y describan lo que tienen: cuántas imágenes, de cuántas personas, y de qué dimensión es cada imagen.

- Cada imagen es una matriz de píxeles en escala de grises. Si la “aplanan” en un vector, ¿cuántos números hay que almacenar por rostro crudo? Ese número (los píxeles por imagen, alto $\times$ ancho) es la dimensión del problema y lo que habría que almacenar por cada rostro sin comprimir; es el punto de partida del argumento de compresión ante el cliente.
- Grafiquen la distribución de imágenes por persona e identifiquen al individuo con más fotos. ¿Qué tan desbalanceada está la base? Guarden esta cifra: la necesitarán en el Paso 5.
- Visualicen algunas imágenes (por ejemplo, las de Serena Williams). ¿Qué variabilidad observan dentro de una misma persona (iluminación, pose, gesto)? ¿Qué le exige eso a un sistema de reconocimiento facial?

Paso 2: El rostro promedio

Calculen el rostro promedio (el promedio de cada píxel a través de todas las imágenes) y gráfíquenlo. Luego resten ese rostro promedio a cada imagen y gráfíquen algunas imágenes centradas.

- ¿Qué “es” el rostro promedio y por qué tiene aspecto de cara? ¿Qué información queda en una imagen después de restárselo?
- ¿Por qué es necesario centrar antes de la SVD? Conecten con lo visto en las dos primeras semanas del curso
- En el taller anterior la discusión fue centrar *y estandarizar*. Aquí todas las variables son píxeles en la misma escala: ¿tiene sentido dividir cada píxel por su desviación estándar? Decidan y justifiquen.

Paso 3: Calculen la SVD y examinen las *eigenfaces*

Apliquen la descomposición en valores singulares a la matriz de imágenes centradas. Pueden hacerlo con álgebra lineal explícita (`np.linalg.svd`, como en los cuadernos de la semana) o con `sklearn`; ambas rutas son válidas. Lo que se califica es que entiendan y defiendan lo que hicieron.

- Gráfíquen los valores singulares y la proporción de varianza acumulada. ¿Cuántas dimensiones se necesitan para capturar el 80%, 90% y 95% de la varianza? ¿Qué les dice eso sobre cuán “redundantes” son los píxeles de un rostro?
- Visualicen las primeras *eigenfaces* (las primeras columnas de V , re-dibujadas como imágenes). ¿Qué patrones parecen capturar las primeras: iluminación, orientación, rasgos? ¿Cómo le explicarían al cliente, sin jerga, qué es una *eigenface*?

Paso 4: Compresión y ranking de configuraciones

Cada rostro puede aproximarse con solo K coordenadas sobre las *eigenfaces*, más el rostro promedio. Elijan una grilla de valores candidatos (por ejemplo, $K \in \{10, 25, 50, 100, 250, 500\}$) y, para las imágenes de Serena Williams, comparen visualmente las reconstrucciones con las originales.

El costo por rostro es solo K (la base se comparte entre todos); comparen las configuraciones por ese costo marginal.

- Construyan la tabla comparativa (*ranking*) de configuraciones: para cada K , la varianza capturada, las dimensiones que se guardan por rostro (K , frente al

rostro crudo) y una valoración de la calidad de reconstrucción (visual y/o numérica, por ejemplo el error de reconstrucción).

- ¿A partir de qué K la cara reconstruida es reconocible para un humano? ¿Ese es el criterio que le importa al cliente, o lo que importa es otra cosa (Paso 5)?
- Traduzcan la compresión a lenguaje de negocio: “con $K = \dots$ almacenamos el ___% de los números originales”. Cuiden el lenguaje: la tabla ordena configuraciones bajo criterios explícitos, no declara un “ganador” universal.

Paso 5: Verificación de identidad y desempeño

El piloto necesita demostrar que las coordenadas comprimidas son suficientes para verificar la identidad de un individuo.

Tomen a George W. Bush como usuario piloto: construyan una variable binaria (1 si la imagen es de él, 0 si no) y un clasificador logístico que la prediga usando las primeras K coordenadas como predictores.

- Dividan la base 80/20 (random_state=10101). Decidan sobre qué datos calculan la SVD: ¿solo con entrenamiento, o con toda la base? ¿Qué pasaría si las imágenes de prueba participaran en la construcción de las *eigenfaces*? Justifiquen su elección: esta decisión afecta directamente la credibilidad de la evaluación.
- Antes de evaluar la calidad de su modelo, calculen la referencia ingenua: si un sistema respondiera “no es el usuario” ante *todas* las imágenes, ¿qué *accuracy* obtendría en la muestra de prueba? A la luz de ese número, ¿es el *accuracy* la métrica que le presentarían al cliente? Elijan las métricas apropiadas (matriz de confusión, precisión, sensibilidad/*recall*, F1) y justifiquen.
- Los dos errores no cuestan lo mismo: un falso positivo deja entrar a un extraño; un falso negativo deja a un empleado bloqueado en el torniquete. ¿Cuál es más grave para el cliente? ¿Cómo se refleja esa asimetría en la métrica que priorizan?
- Evalúen el desempeño para varios valores de K de su grilla del Paso 4 y completen su ranking de configuraciones con esta evidencia. Elijan el K que recomendarán, justificando el punto de equilibrio entre el número de dimensiones y el desempeño. (Si la evaluación de muchos K resulta pesada, pueden apoyarse en [Google Colab](#).)

- Repitan la verificación tomando ahora a Serena Williams como usuaria piloto y comparen el desempeño. ¿Funciona igual de bien que con Bush? Piensen en las características de esta usuaria, qué les dice sobre el desempeño de su modelo y las salvaguardas operativas.

Paso 6: Recomendación

Luego del análisis realizado:

- ¿Qué le recomiendan al cliente: aprobar el piloto, aprobarlo con condiciones, o no aprobarlo?
- Si recomiendan avanzar: ¿con qué K, con qué métricas de desempeño esperadas y con qué salvaguardas operativas?
- ¿Qué limitaciones deben advertir? La composición de LFW frente a la población real de empleados, la antigüedad y origen de las fotos, lo que su evaluación no midió, las implicaciones éticas y de privacidad de desplegar reconocimiento facial, y la sensibilidad de sus conclusiones a las decisiones que tomaron en los Pasos 2 y 5.

Extensión (opcional): el juego del impostor

En esta extensión opcional, examinen cómo funciona esta lógica al aplicarla a imágenes de individuos no vistos. Para implementarlo, reserven varias identidades completas (todas sus imágenes) y no las usen en la construcción de las *eigenfaces*. Con el modelo ya elegido, presenten esas imágenes como intentos de acceso y cuenten cuántas se aceptan como intentos del usuario piloto: son los falsos positivos frente a intentos reales de usuarios desconocidos.