

Paso1. Guia caso-taller: ¿Reconciliar fotos con clustering?



K-medias, K-medoides, validación de clustering y recomendación operativa

El problema

Una empresa que administra los registros de empleados migró recientemente su sistema de fotos de carné a una nueva plataforma. Las imágenes atravesaron el proceso de migración intactas, pero, debido a un error de configuración, el sistema antiguo no transfirió las etiquetas de identidad de forma confiable. Hoy la empresa tiene un archivo grande de aproximadamente 10.000 fotos de empleados, pero ya no sabe con certeza a quién pertenece cada una.

Reasignar manualmente esa cantidad es un trabajo enorme. El equipo de analítica de RRHH propone utilizar *clustering*: agrupar automáticamente las fotos por similitud facial, reducir el lote a grupos que después revise un analista humano (p. ej. “estos 47 rostros probablemente son la misma persona”) para confirmar identidades. Si el clustering es confiable, pueden automatizar el proceso y confiar en él para reconciliar el archivo completo.

Su firma consultora ha sido contratada para evaluar si esta estrategia de *clustering* es viable y, de serlo, bajo qué condiciones debería implementarse.

Para evaluar la viabilidad de esta estrategia antes de considerar su aplicación al archivo completo, se utilizará la base de datos **Olivetti Faces** como entorno de prueba controlado. El conjunto contiene imágenes de 40 personas, con 10 fotografías por individuo, y permite evaluar el desempeño del *clustering* en un escenario en el que las identidades reales son conocidas.

Desde el primer minuto de su presentación deberán responder:

¿Es viable utilizar *clustering* para apoyar la reconciliación del archivo de fotos de la empresa? Si es así, ¿qué enfoque recomiendan y bajo qué condiciones y salvaguardas debería implementarse?

El clustering les permitirá agrupar rostros, pero no generará automáticamente una recomendación de confianza ni una estrategia operativa. Su equipo deberá justificar la transición entre:

- La estructura estadística encontrada en los datos;

- La construcción del ranking de configuraciones;
- La recomendación empresarial y los controles que la empresa debe aplicar en producción.

Los datos

Trabjarán con la base de datos **Olivetti Faces**, que contiene 400 imágenes de 40 personas, con 10 fotografías por individuo. Las imágenes fueron capturadas en condiciones relativamente controladas, aunque presentan variaciones en la iluminación, la expresión facial, la pose y el uso de gafas.

Carguen los datos mediante `fetch_olivetti_faces()` de `sklearn.datasets`. Para garantizar la reproducibilidad de los resultados, utilicen `random_state=123` y `n_init=10` en K-medias.

Tengan en cuenta que **Olivetti representa un escenario más controlado que el archivo real de la empresa**. En producción podrían existir mayores diferencias en la iluminación, la pose, la fecha de captura y la apariencia. Por ello, los resultados obtenidos con esta base deben interpretarse como evidencia de viabilidad y no como garantía de desempeño del archivo completo.

Los productos de la entrega

El equipo entregará dos productos conectados entre sí y cada uno en su respectivo link designados como “entrega calificada por el personal” (en estos podrá consultar la rúbrica):

1. Cuaderno de análisis (4% de la calificación)

El cuaderno será el soporte técnico completo y reproducible de la recomendación.

Deberá documentar:

- La exploración y preparación de los datos;
- Las decisiones tomadas antes y durante el clustering;
- La construcción del ranking de configuraciones;
- El análisis de sensibilidad frente a diferentes algoritmos y preprocesamiento;
- La recomendación final y los controles operativos necesarios;
- Las limitaciones y los próximos pasos.

Cada decisión deberá estar acompañada de una breve justificación. No basta con mostrar código o resultados.

El cuaderno deberá permitir que un lector técnicamente competente:

- Reproduzca el análisis;
- Entienda qué decisiones afectaron el resultado (algoritmo, dimensionalidad, número de clusters);
- Verifique las cifras utilizadas en la presentación;
- Evalúe la robustez de la recomendación.

2. Presentación ejecutiva (12% de la calificación)

La presentación estará dirigida al cliente. Su propósito no es explicar el cuaderno ni describir, paso a paso, cómo se realizó el clustering. Su propósito es comunicar una decisión clara y respaldada por evidencia. Desde los primeros 60–90 segundos deberá responder:

¿Es viable utilizar *clustering* para apoyar la reconciliación del archivo de fotos de la empresa? Si es así, ¿qué enfoque recomiendan y bajo qué condiciones debería implementarse?

La presentación deberá incluir:

- Una recomendación clara sobre si la empresa debería avanzar con la estrategia, descartarla o implementarla bajo ciertas condiciones;
- Los principales argumentos que la respaldan;
- El ranking de configuraciones y la evidencia de su calidad;
- Las fortalezas y debilidades de la configuración recomendada;
- Los trade-offs y las limitaciones (lote controlado vs. archivo real);
- Los controles operativos que la empresa debe aplicar en producción (p. ej. umbral de revisión humana, tasa de auditoría muestral);
- Los próximos pasos.

Todas las cifras, tablas y gráficas utilizadas en la presentación deberán estar respaldadas en el cuaderno.

Recuerde que el cuaderno contiene el análisis completo y sirve como evidencia de su trabajo, mientras que la presentación selecciona únicamente la evidencia necesaria para respaldar su recomendación.

Guía recomendada de análisis

La siguiente guía propone una ruta para desarrollar el análisis y construir los dos productos de la entrega. No es una receta única: cada equipo podrá tomar decisiones metodológicas diferentes, siempre que sean técnicamente correctas, estén claramente documentadas y sean coherentes con la pregunta de negocio.

El análisis deberá mostrar cómo se pasa de la exploración de la estructura estadística de los datos a la construcción de un ranking de configuraciones y, finalmente, a una recomendación empresarial.

Paso 1. Exploración de los datos y el problema de negocio

Carguen la base Olivetti y describan lo que tienen:

- ¿Cuántas imágenes en total? ¿De cuántas personas? ¿Cuántas imágenes por persona?
- ¿Cuál es la dimensión de cada imagen (número de píxeles)?
- Visualicen varias imágenes de la misma persona y otras de personas distintas. ¿Qué variabilidad observan en la misma persona (iluminación, pose, expresión)? ¿Cómo se diferencian los rostros de las personas? ¿Qué le exige eso a un sistema de clustering automático?
- Reflexionen: en el archivo real de la empresa, los desafíos serán mayores que en Olivetti (iluminación de cámaras distintas, años distintos, poses menos controladas). ¿Qué riesgos implica esto para un piloto que valida en condiciones controladas?

Paso 2. Preparación de los datos

Las imágenes deberán vectorizarse (aplanar cada matriz 64×64 en un vector de 4096 píxeles) y transformarse en una matriz en la que cada fila es una imagen y cada columna es un píxel.

Antes de aplicar clustering, deberán tomar decisiones sobre normalización:

¿Estandarizar los píxeles (restar la media, dividir entre la desviación estándar)? ¿Por qué sí o por qué no?

El espacio de píxeles crudos tiene una característica: cada píxel es una dimensión, así que el ruido visual (iluminación, pequeños cambios de pose) contribuye a distancias muy grandes. Esta maldición de la dimensionalidad afectará la calidad del clustering. Tendrán que evaluar si trabajar en el espacio crudo o reducir dimensión es beneficioso.

Paso 3. Clustering con K conocido: K-medias

Apliquen K-medias con $k=40$ (el número conocido de personas en el lote) y evalúen la calidad del agrupamiento.

Un reto fundamental: en clustering no supervisado, las etiquetas de cluster son arbitrarias (es decir, el cluster 0 podría etiquetarse como cluster 5 sin cambiar el significado). Comparar directamente `cluster_asignado == identidad_real` no funciona. Necesitarán alinear clusters con identidades reales usando métricas que sean insensibles a la permutación de etiquetas:

- **Pureza:** mide qué tan homogéneo es cada cluster respecto a la identidad real. Para cada cluster, se identifica la persona con mayor número de imágenes y se calcula qué proporción del cluster pertenece a esa persona. Una pureza cercana a 1 indica poca mezcla entre identidades.
- **Matriz de confusión alineada:** como los números asignados a los clusters son arbitrarios, busquen la correspondencia entre clusters e identidades que produzca el mayor número de coincidencias. Utilicen esta correspondencia para construir una matriz de confusión e identificar visualmente qué identidades se agrupan correctamente y cuáles tienden a mezclarse.

Calculen las métricas anteriores e interpreten los resultados:

- ¿Qué indican sobre la calidad del agrupamiento en el espacio de píxeles?
- ¿Qué tan homogéneos son los clusters respecto a las identidades reales?
¿Qué implicaciones tendría ese nivel de pureza en un contexto de uso real?
- Visualicen 2–3 clusters y examinen su composición. Identifiquen posibles mezclas entre identidades y analicen si los errores parecen estar asociados con características como la iluminación, la expresión, la pose o el uso de gafas.

Paso 4. Reducción de dimensión: impacto de PCA

Uno de los aprendizajes clave de las semanas previas es que la varianza en el espacio de píxeles crudo está dominada por ruido (iluminación, pequeños cambios de pose), no por identidad. Intenten reducir la dimensionalidad con PCA.

Apliquen PCA y retengan suficientes componentes para explicar el 95% de la varianza. ¿Cuántos componentes necesitan? Eso les indica cuánta “estructura subyacente” hay en los rostros.

Luego, repitan el K-medias con $K=40$ sobre las coordenadas PCA (en lugar de los píxeles crudos):

- ¿Mejoran las métricas de los pasos anteriores?
- Visualicen de nuevo varios clusters: ¿la composición cambió? ¿Se mezclan menos identidades? ¿Hay clusters que se dividieron o fusionaron?
- Reflexionen: ¿por qué la reducción de dimensión cambió los resultados? ¿Qué información estaban perdiendo al usar píxeles crudos?

Esta comparación es central: el espacio de píxeles vs. el espacio PCA representa decisiones fundamentales sobre qué es “similar” en un rostro.

Paso 5. K-medoides: robustez a outliers

El algoritmo K-medias calcula el centroide de cada cluster (el promedio de todas las imágenes en el cluster). El centroide es una cara “borrosa”, promedio, que puede no corresponder a ninguna imagen real. Además, el centroide es sensible a outliers: una o dos fotos atípicas pueden moverlo.

K-medoides, en cambio, elige a la imagen más central en cada cluster como representante (el medoide). El medoide es siempre una imagen real.

Apliquen K-medoides (también con $K=40$, sobre el espacio completo y el espacio con reducción de dimensión PCA) y comparen:

- ¿Mejoran las métricas de los pasos anteriores?
- Visualicen los centroides de K-medias y los medoides de K-medoides para un cluster problemático (uno que mezcle identidades, por ejemplo). ¿Qué diferencia ves? ¿El medoide es más “reconocible”?
- Reflexionen: en un contexto operativo (donde el sistema debe sugerir al analista humano “estas imágenes probablemente son la misma persona”), ¿cuál es más útil: ver un promedio borroso (centroide) o ver una foto real (medoide)?

Paso 6. ¿Qué ocurre cuando no conocemos K?

Hasta ahora han trabajado con $K=40$ porque conocen el número de personas presentes en la base. Sin embargo, en una aplicación real esta información podría no estar disponible.

Exploren distintos valores de K y analicen cómo cambia el agrupamiento. Para orientar esta comparación, utilicen:

- **Método del codo:** grafiquen la inercia para distintos valores de K e identifiquen si existe un punto a partir del cual aumentar el número de clusters produce mejoras cada vez menores.
- **Coeficiente de silueta:** comparen qué tan cohesionados y separados están los clusters para distintos valores de K .

A partir de los resultados, discutan:

- ¿Los dos criterios sugieren valores similares de K ?
- ¿El valor $K=40$ parece razonable según estos criterios?
- ¿Qué dificultades encuentran al intentar determinar el número de clusters sin conocer previamente las identidades?

El objetivo no es necesariamente encontrar un único valor de K “correcto”, sino analizar qué tan sensible es el clustering a esta decisión y qué implicaciones tendría en un contexto donde el número de personas no es conocido de antemano.

Paso 7. Integración de resultados y recomendación

Integren los resultados obtenidos a lo largo del análisis y comparen los principales enfoques evaluados:

- K -medias sobre píxeles crudos;
- K -medias después de aplicar PCA;
- K -medoides sobre el espacio reducido;
- diferentes valores de K .

Apoyen la comparación en la **pureza, el coeficiente de silueta, la matriz de confusión alineada y la inspección visual de los clusters**. Tengan en cuenta que cada una aporta información distinta y que la decisión no debe depender de un único resultado.

A partir de esta evidencia, formulen una recomendación para el cliente:

- ¿Los resultados sugieren que el *clustering* puede ser útil para apoyar la reconciliación de las fotografías?
- ¿Qué enfoque produjo los resultados más convincentes y por qué?
- ¿Qué fortalezas y limitaciones identificaron en el enfoque recomendado?
- ¿Hasta qué punto los resultados obtenidos con Olivetti pueden trasladarse al archivo real de la empresa?
- ¿Qué sería necesario evaluar antes de aplicar el método al archivo completo?

La recomendación deberá estar respaldada por la evidencia del análisis y distinguir claramente entre lo que se puede concluir a partir de Olivetti y aquello que todavía requeriría validación con datos reales de la empresa.