

Paso 1. Guia taller: "¿A quién le vendemos?"



Clustering jerárquico, DBSCAN y una recomendación de campaña

El caso

Una cadena de tiendas va a lanzar una campaña de mercadeo y quiere dejar de enviar el mismo mensaje a toda su base de clientes. La hipótesis de la dirección de mercadeo es que entre los clientes que tienen la tarjeta de fidelización conviven perfiles distintos y que hablarle a cada uno con una oferta propia es potencialmente más beneficioso que una promoción general.

El presupuesto, sin embargo, es limitado: alcanza para **dos campañas diferenciadas**. Cada una con su mensaje, su oferta y su canal. El problema, entonces, es decidir en quiénes enfocarse.

El equipo de analítica propone usar *clustering* en los datos de la tarjeta de fidelización para descubrir esos perfiles sin definirlos de antemano. Antes de comprometer el presupuesto, la dirección quiere saber si el ejercicio produce grupos en los que pueda confiar. Como piloto, se entregan los datos de fidelización de una tienda: 200 clientes.

El cliente los contrató para elaborar una recomendación de decisión mediante una presentación en video. Desde el primer minuto, la presentación debe responder la pregunta del cliente:

¿Debe la empresa segmentar su base de clientes mediante el clustering para focalizar la campaña? Si es así, ¿con qué método, cuántos segmentos y en cuáles dos enfocar las campañas, y por qué?

Concretamente, la presentación debe tener:

1. Una recomendación clara: segmentar o no, con qué procedimiento y qué dos segmentos reciben el presupuesto.

2. La evidencia que la sustenta: ser capaz de responder las preguntas del cliente: ¿los grupos existen en los datos o los produjo el algoritmo? ¿El resultado cambia si cambiamos un parámetro?

Los datos

Trabajarán con el siguiente archivo:

Este archivo, que contiene los registros de fidelización de 200 clientes de la tienda y cinco variables:

- Id_Cliente: identificador del cliente.
- Género: género del cliente (mujer, hombre).
- Edad: edad en años.
- Ingreso: ingreso anual.
- Puntaje_Gasto: indicador construido por la cadena que mide con qué frecuencia compra el cliente en la tienda, en una escala donde 100 es el puntaje más alto.

Los productos de la entrega

El único entregable es un **video de 10 a 15 minutos** (100% de la calificación), evaluado por sus pares con la rúbrica correspondiente.

Es una presentación ejecutiva dirigida al cliente, no un recorrido por el análisis: su propósito es comunicar la decisión (la recomendación y la evidencia que la sustenta), no explicar el código.

En esta actividad no se solicita que entregue un cuaderno o scripts que respalden su análisis, pero se espera que toda cifra o gráfica del video provenga de un análisis que el grupo pueda sustentar. Si el profesor complementario identifica inconsistencias, conflictos de interés, falta de justificación o cualquier otra circunstancia, podrá solicitarle los códigos que respalden su análisis. Es buena práctica, entonces, tenerlos debidamente documentados.

Guía recomendada de análisis

La siguiente guía propone una ruta para desarrollar el análisis. No constituye una receta única: cada equipo podrá tomar decisiones metodológicas distintas, siempre que sean técnicamente correctas, estén claramente documentadas y sean coherentes con la pregunta planteada en el taller.

Para que los resultados sean comparables entre grupos, su análisis debe evaluar al menos estas **cinco configuraciones**:

1. Clustering jerárquico con enlace de Ward usando ingreso y puntaje de gasto estandarizados.
2. Clustering jerárquico con un enlace distinto de Ward, usando las mismas variables estandarizadas.
3. Clustering jerárquico con enlace de Ward sobre el ingreso y el puntaje de gasto sin estandarizar.
4. DBSCAN aplicado al ingreso y al puntaje de gasto estandarizados.
5. DBSCAN con distancia de Gower, incorporando género y grupo etario.

Paso 1: Exploración y el problema de negocio

Carguen los datos y descríbanlos: cuántos clientes, cuáles son las estadísticas descriptivas de las variables.

- Grafiquen el ingreso en función del puntaje de gasto. ¿Ven estructura a simple vista? ¿Cuántos grupos diría un observador humano que hay y qué tan seguro estaría de esa respuesta?
- Comparen ingreso y puntaje de gasto entre mujeres y hombres y entre grupos etarios (18-24, 25-34, 35-44, 45-54, 55-64, 65+). Evalúen si las diferencias observadas son estadísticamente significativas (apliquen el test correspondiente)

Paso 2: Clustering jerárquico

Construyan y grafiquen el dendrograma a partir del ingreso y del puntaje de gasto.

- Piensen cuidadosamente en los tipos de enlaces a utilizar, los puntos de corte y las conclusiones que se derivan de cada uno. Apóyense en el dendrograma y en alguna medida de calidad del agrupamiento, como el coeficiente de silueta, y compárenlos entre sí.
- Cuidado con la circularidad: el cliente puede financiar dos campañas. ¿El número de segmentos proviene de la estructura de los datos o del presupuesto? Son dos preguntas distintas y conviene no confundirlas: primero, cuántos grupos hay; después, en cuáles se focaliza.

Paso 3: DBSCAN

Apliquen DBSCAN a las mismas dos variables del paso anterior.

- Justifiquen su elección de los hiperparámetros.

- Interpreten los extremos: ¿qué significa que una gran proporción de los clientes quede marcada como ruido? ¿Y qué significa que todos queden en un solo grupo? ¿Cuál de las dos situaciones es más engañosa para alguien que solo ve el resultado final?
- Comparen los grupos de DBSCAN con los del paso anterior. Piensen en las diferencias y similitudes, y en lo que esto implica para su recomendación.

Paso 4: Todas las variables

Hasta aquí usaron dos variables numéricas. La base también incluye el género y la edad. Revisiten todo el análisis e incorporen todas las variables. ¿Cambian las conclusiones? ¿Cómo se complementan con las diferencias descriptivas surgidas durante la exploración de los datos?

- Reflexionen sobre si agregar estas variables les dio más foco, o cambió la pregunta sin avisar. ¿Qué peso tienen dos variables categóricas frente a dos variables numéricas en la distancia?
- Aunque técnicamente podrían segmentar por género, ¿deberían hacerlo? Consideren qué le costaría a la cadena una campaña dirigida por género si la variable no distinguiera entre los comportamientos de compra.

Paso 5: Ranking y recomendación

Consoliden esta exploración y ordénenla según criterios explícitos: calidad del agrupamiento, estabilidad frente a cambios de parámetros e interpretabilidad comercial de los grupos que produce.

Con la configuración que recomiendan, construyan el segundo ranking, el de los segmentos, ordenados por qué tan atractivos son para el presupuesto de focalización. Definan explícitamente qué hace atractivo a un segmento; piensen en sus atributos: por ejemplo, el tamaño puede ser un criterio, pero no necesariamente el mejor.

A partir de ahí, formulen la recomendación:

- ¿Le recomiendan al cliente segmentar, segmentar con condiciones o no segmentar?
- ¿Con qué procedimiento y cuántos segmentos? ¿Cuáles dos reciben el presupuesto de focalización y con qué mensaje?
- ¿Qué consideraciones y/o limitaciones debería tener en cuenta la empresa?