

Paso 1. Guía caso-taller: ¿Recomendar lo que ya suena o ayudar a descubrir?



Filtrado colaborativo, factorización latente, reglas de asociación y recomendación de despliegue

El problema

Una plataforma regional de streaming musical ha construido en pocos años un catálogo de más de 17.000 artistas, pero su consumo está muy concentrado: la página inicial siempre recomienda los mismos nombres, los sellos independientes se quejan de que sus artistas nunca aparecen y el equipo de producto observa que los usuarios escuchan cada vez lo mismo hasta que se aburren y cancelan la suscripción.

La dirección quiere lanzar un módulo llamado **“Descubre”**: una franja en la aplicación que sugiera a cada usuario diez artistas que todavía no ha escuchado y que valgan la pena escuchar. El equipo de producto ha propuesto varios enfoques, desde simplemente recomendar lo más escuchado por todos hasta construir un modelo de factores latentes, pero no hay acuerdo sobre cuál desplegar ni sobre qué evidencia debería sustentar esa decisión.

Su firma consultora ha sido contratada para evaluar los enfoques disponibles y recomendar cuál debería implementarse, bajo qué condiciones y con qué resguardos.

Para evaluar los enfoques antes de comprometer recursos, se utilizará una base histórica de consumo musical de la plataforma **Last.fm**, publicada abiertamente por GroupLens, que permite comparar los distintos motores de recomendación con usuarios y artistas reales.

Desde el primer minuto de su presentación deberán responder:

¿Qué motor de recomendación debería desplegar la plataforma en el módulo “Descubre”, y bajo qué condiciones y salvaguardas debería implementarse?

Los algoritmos de recomendación les permitirán generar listas de artistas, pero no determinan por sí solos qué lista es mejor para el negocio ni qué controles necesita el módulo en producción. Su equipo deberá justificar la transición entre:

- la estructura estadística encontrada en los datos;

- la construcción del ranking de motores;
- la recomendación empresarial y los controles que la plataforma debe aplicar en producción.

Los datos

Trabajarán con los datos de consumo musical de [Last.fm](#) publicados por [GroupLens](#) en el marco del taller HetRec 2011. Los archivos están en la carpeta data, junto con un README con información adicional sobre las bases:

- artists.dat contiene el identificador del artista (id), su nombre (name), el enlace a su página en Last.fm (url) y el enlace a su imagen (pictureURL). Varios de estos enlaces están rotos.
- user_artists.dat contiene el identificador del usuario (userID), el identificador del artista que escuchó (artistID) y el número de veces que lo reprodujo (weight).

Ambos archivos están separados por tabulaciones. En conjunto registran 1.892 usuarios, 17.632 artistas y 92.834 pares usuario-artista observados. Esto significa que solo se observa cerca del 0,3% de las combinaciones posibles: la matriz de consumo es extremadamente poco densa y esa falta de densidad es el problema central de cualquier sistema de recomendación.

Hay tres características de estos datos que condicionan la interpretación de cualquier resultado y que el equipo deberá tratar de forma explícita:

- **La lista de cada usuario está truncada.** Ningún usuario aparece con más de 50 artistas: la base recoge únicamente los artistas más escuchados por cada uno. Que un artista no aparezca en la lista de un usuario no significa que no le guste, ni siquiera que no lo haya escuchado; significa que no está entre sus primeros cincuenta. Esta asimetría entre lo observado y lo no observado es decisiva para interpretar qué es un “acierto” y qué es un “error” de un recomendador.

- **El número de reproducciones no es una calificación.** La mediana de reproducciones por par usuario-artista es 260, pero el máximo supera las 350.000. Un usuario con cifras muy altas no está expresando una preferencia más intensa: puede simplemente escuchar más música, o haber dejado el reproductor encendido. El equipo deberá decidir si trabaja con el conteo crudo, si lo transforma, si lo normaliza por usuario o si lo binariza, y justificar esa decisión.
- **Los datos son de 2011.** El catálogo, los hábitos de consumo y los artistas populares han cambiado desde entonces. Por tanto, el resultado no debe presentarse como una recomendación definitiva sobre qué artistas mostrar hoy: el análisis sirve para elegir el motor y sus condiciones de despliegue, no para fijar el contenido del módulo.

Para garantizar la reproducibilidad de los resultados, establezcan `random_state=123` en cualquier procedimiento que involucre aleatoriedad y trabajen con listas de 10 recomendaciones por usuario.

Los productos de la entrega

El equipo entregará dos productos conectados entre sí y cada uno en su respectivo link designados como “entrega calificada por el personal” (en estos podrá consultar la rúbrica):

1. Cuaderno de análisis (4% de la calificación)

El cuaderno será el soporte técnico completo y reproducible de la recomendación.

Deberá documentar:

- la exploración y preparación de los datos;
- las decisiones tomadas sobre la matriz usuario-artista y su transformación;
- la construcción de cada uno de los motores de recomendación evaluados;
- la construcción del ranking de motores y los criterios utilizados para compararlos;
- la recomendación final y los controles operativos necesarios;
- las limitaciones y los próximos pasos.

Cada decisión deberá estar acompañada de una breve justificación. No basta con mostrar código o resultados.

El cuaderno deberá permitir que un lector técnicamente competente:

- reproduzca el análisis;
- entienda qué decisiones afectaron el resultado (transformación de los datos, algoritmo, hiperparámetros, criterios de comparación);
- verifique las cifras utilizadas en la presentación;
- evalúe la robustez de la recomendación.

2. Presentación ejecutiva (12% de la calificación)

La presentación estará dirigida al cliente. Su propósito no es explicar el cuaderno ni describir paso a paso cómo se construyó cada motor. Su propósito es comunicar una decisión clara y respaldada por evidencia.

Desde los primeros 60–90 segundos deberá responder:

¿Qué motor de recomendación debería desplegar la plataforma en el módulo “Descubre”, y bajo qué condiciones debería implementarse?

La presentación deberá incluir:

- una recomendación clara sobre qué motor desplegar, o sobre la decisión de pilotear con controles o no lanzar el módulo todavía;
- los principales argumentos que la respaldan;
- el ranking de motores y la evidencia que lo sustenta;
- las fortalezas y debilidades del motor recomendado;
- los trade-offs de la recomendación, en particular entre acertar con lo que el usuario ya escucharía y ayudarlo a descubrir;
- los próximos pasos y la decisión que tiene que tomar el cliente.

Todas las cifras, tablas y gráficas utilizadas en la presentación deberán estar soportadas en el cuaderno.

Recuerde que el cuaderno contiene el análisis completo y sirve de evidencia de su trabajo, mientras que la presentación selecciona únicamente la evidencia necesaria para respaldar su recomendación.

Guía recomendada de análisis

La siguiente guía propone una ruta para desarrollar el análisis y construir los dos productos de la entrega. No es una receta única: cada equipo podrá tomar decisiones metodológicas diferentes, siempre que sean técnicamente correctas, estén claramente documentadas y sean coherentes con la pregunta de negocio.

El análisis deberá mostrar cómo se pasa de la exploración de la estructura estadística de los datos a la construcción de un ranking de motores y, finalmente, a una recomendación empresarial.

Paso 1. Exploración de los datos y el problema de negocio

Carguen las dos bases y únanlas de forma que cada par usuario-artista quede identificado con el nombre del artista y con el número de reproducciones.

Documenten las decisiones de nombres de columnas que tomen, porque el resto del análisis dependerá de ellas.

Describan lo que tienen:

- ¿Cuántos usuarios y cuántos artistas hay en la base? ¿Cuántos pares usuario-artista se observan?
- ¿Cuál es la distribución del consumo por artista? Calcúlenla de dos formas: sin ponderar, es decir contando cuántos usuarios distintos escuchan a cada artista, y ponderando por el número de reproducciones. ¿Qué diferencias encuentran entre ambas? ¿Qué artistas cambian de posición y por qué? ¿Qué les dice esa comparación sobre qué significa ser “popular” en esta plataforma?
- ¿Cuántos artistas son escuchados por un solo usuario? ¿Qué proporción del catálogo representan? Si el cliente quiere hacer visible su catálogo, ¿qué implica esta cifra?
- Para el usuario 8 (userID==8), examinen su distribución de reproducciones relativas. Presenten los resultados en tablas y gráficas. ¿Qué patrón encuentran entre los artistas que escucha y las veces que los reproduce? ¿Qué se puede decir de sus preferencias? **Este usuario servirá como caso ilustrativo a lo largo de todo el análisis.**
- Reflexionen: el módulo “Descubre” debe sugerir artistas **nuevos y relevantes**. A la luz de la distribución del consumo que acaban de observar, ¿qué tan fácil o difícil parece ese objetivo?

Paso 2. Preparación de los datos: qué significa “similar”

Construyan la matriz usuario-artista, donde cada fila corresponde a un usuario, cada columna a un artista y cada celda al consumo observado. Verifiquen su dimensión y su nivel de dispersión.

Antes de construir cualquier motor, deberán tomar decisiones sobre cómo representar el consumo, y cada una define implícitamente qué significa que dos usuarios o dos artistas sean “similares”:

- ¿Usan el número de reproducciones crudo, una transformación (por ejemplo logarítmica), una normalización por usuario, o una versión binaria que solo registre si el usuario escuchó al artista o no? ¿Qué gana y qué pierde cada opción a la luz de la cola pesada documentada en el Paso 1?
- ¿Qué representa una celda vacía? Recuerden que la base está truncada a los cincuenta artistas más escuchados por usuario. Si tratan los ceros como “no le gusta”, ¿qué sesgo introducen? Si los tratan como “desconocido”, ¿qué implica eso para cada algoritmo?
- ¿Qué hacen con los artistas escuchados por un solo usuario? ¿Los conservan, los filtran, aplican un umbral mínimo? Justifiquen la decisión y tengan presente que esos artistas son justamente los que el cliente querría hacer visibles.

Estas decisiones son transversales: afectarán a los cinco motores por igual, por lo que conviene fijarlas y documentarlas antes de continuar.

Paso 3. Línea base: recomendación por popularidad

El primer enfoque que propuso el equipo de producto es el más sencillo: recomendar a cada usuario los artistas que más gente escucha, excluyendo los que ya escucha.

Construyan dos versiones:

- **Promedio simple:** basado únicamente en el número de usuarios que escucha a cada artista, sin considerar cuántas veces lo reproducen. Generen una tabla o gráfica con diez recomendaciones para el usuario 8, expliquen con cuidado el procedimiento y justifiquen sus elecciones.
- **Promedio ponderado:** basado en el número de usuarios que escucha a cada artista, ponderando por el número de reproducciones. Generen de nuevo diez recomendaciones para el usuario 8 y compárenlas con las del enfoque anterior.

Antes de pasar al siguiente motor, examinen con atención lo que acaban de construir:

- ¿Qué tan distintas son las dos listas entre sí?
- Generen las recomendaciones para dos o tres usuarios adicionales con perfiles distintos al del usuario 8. ¿Qué tan distintas son sus listas? ¿Cuántos artistas comparten?
- ¿Qué proporción de lo recomendado pertenece al grupo de artistas más populares de toda la base?
- Un motor así acertaría con frecuencia, en el sentido de que sugiere artistas que mucha gente efectivamente escucha. ¿Resuelve el problema que planteó el cliente? ¿Qué relación tiene esto con la queja de los sellos independientes?

Esta línea base es importante: cualquier motor más sofisticado que construyan deberá justificar por qué vale la pena frente a ella.

Paso 4. Vecindad: similitud de coseno

El segundo enfoque consiste en recomendar con base en la similitud entre perfiles de consumo. Utilizando el promedio ponderado de reproducciones, generen una tabla o gráfica con diez recomendaciones para el usuario 8, calculando los pesos mediante la similitud de coseno. Expliquen con cuidado el procedimiento y justifiquen sus elecciones.

- Decisiones que deberán tomar y justificar:
- ¿Calculan la similitud entre usuarios o entre artistas? ¿Qué diferencia práctica tiene cada opción para el módulo “Descubre”?
- ¿Sobre qué versión de la matriz calculan la similitud: cruda, normalizada o binaria? Conecten esta decisión con lo discutido en el Paso 2.
- ¿Utilizan a todos los vecinos o solo a los más cercanos? ¿Cuántos? ¿Qué ocurre con la recomendación cuando ese número cambia?

Comparen las recomendaciones con las del paso anterior. ¿Qué cambió y por qué? ¿Aparecen artistas menos populares? Si no aparecen, ¿qué del procedimiento lo explica?

Paso 5. Factorización latente: SVD

El tercer enfoque utiliza la descomposición en valores singulares para representar usuarios y artistas en un espacio de factores latentes. Generen una tabla o gráfica con diez recomendaciones para el usuario 8 usando SVD, expliquen con cuidado el procedimiento y justifiquen sus elecciones.

El análisis debería abordar:

- ¿Cuántos factores retienen y con qué criterio? Recuperen lo trabajado en las semanas anteriores sobre varianza explicada y selección de componentes, y discutan si ese criterio es igual de pertinente aquí, donde el objetivo no es describir la estructura de los datos sino predecir consumo no observado.
- ¿Qué parecen representar los primeros factores? Examinen qué artistas cargan alto en cada uno. ¿Corresponden a géneros, a niveles de popularidad, a algo distinto?
- ¿Cómo se reconstruyen las preferencias no observadas y cómo se convierte esa reconstrucción en una lista de diez recomendaciones?
- ¿Qué ocurre con los artistas escuchados por muy pocos usuarios cuando se reduce la dimensionalidad? ¿La reducción los rescata o los borra?

Comparen las recomendaciones con las de los pasos anteriores.

Paso 6. Reglas de asociación: análisis de canasta

El cuarto enfoque proviene del análisis de canasta de compra: tratar la lista de artistas de cada usuario como una canasta y buscar reglas del tipo “quien escucha a X también escucha a Y”. Utilizando el algoritmo Apriori, generen una tabla o gráfica con diez recomendaciones para el usuario 8, expliquen con cuidado el procedimiento y justifiquen sus elecciones.

Advertencia operativa: **este procedimiento puede tomar mucho tiempo**. Sean cuidadosos al elegir los hiperparámetros del modelo, utilicen las estadísticas descriptivas del Paso 1 para elegir el soporte mínimo y generen únicamente reglas de dos elementos. Pueden aprovechar los recursos de [Google Colab](#) si lo necesitan.

Discutan:

- ¿Qué información aporta una regla de asociación que la similitud de coseno no aporta? ¿En qué se parecen y en qué se diferencian conceptualmente?
- ¿Qué relación hay entre el soporte mínimo que eligieron y el tipo de artistas que pueden aparecer en las reglas? ¿Qué le ocurre a la cola del catálogo cuando se sube el umbral?
- ¿La confianza y el lift de una regla dicen lo mismo sobre su utilidad para el módulo “Descubre”?

Comparen las recomendaciones con las de los pasos anteriores.

Paso 7. Comparación, ranking de motores y recomendación

Integren los resultados y comparen los cinco motores evaluados:

- popularidad simple;
- popularidad ponderada;
- similitud de coseno;
- factorización latente con SVD;
- reglas de asociación con Apriori.

Construyan un ranking de motores y expliquen los criterios con los que lo armaron.

Algunos criterios que pueden considerar, sin que la lista sea obligatoria ni exhaustiva:

- **Solapamiento entre listas:** cuánto se parecen las recomendaciones de un motor a las de otro, y cuánto se parecen las listas de usuarios distintos bajo un mismo motor.
- **Popularidad de lo recomendado:** qué tan conocidos son, en promedio, los artistas que cada motor sugiere.
- **Cobertura del catálogo:** cuántos artistas distintos es capaz de recomendar cada motor si se aplica a todos los usuarios.
- **Novedad y pertinencia respecto al perfil:** qué tan lejos está lo recomendado de lo que el usuario ya escucha, y si la lista sigue siendo plausible para ese usuario.
- **Explicabilidad:** qué tan fácil es decirle al usuario por qué se le recomienda un artista.

Tengan en cuenta que cada criterio aporta información distinta, que varios entran en conflicto entre sí, y que la decisión no debe depender de un único resultado. La forma en que ponderen estos criterios es una decisión del equipo y deberá estar justificada por la pregunta del cliente, no por la conveniencia del algoritmo.

A partir de esta evidencia, formulen una recomendación para el cliente:

- ¿Qué motor recomiendan desplegar en el módulo “Descubre” y por qué?
- ¿Qué trade-off están aceptando entre recomendar lo que el usuario probablemente escucharía de todos modos y ayudarlo a descubrir algo nuevo?
- ¿Qué fortalezas y limitaciones tiene el motor recomendado?

- ¿Qué resguardos y controles operativos necesita el módulo en producción?
- ¿Cómo diseñarían una evaluación objetiva de estas recomendaciones, tanto antes del lanzamiento como después de él? ¿Qué medirían, sobre qué datos y contra qué punto de comparación?
- ¿Qué decisión concreta se le solicita al cliente?

La recomendación deberá estar respaldada por la evidencia del análisis y distinguir claramente entre lo que se puede concluir a partir de estos datos y aquello que todavía requeriría validación con datos reales de la plataforma.